

 ESPE UNIVERSIDAD DE LAS FUERZAS ARMADAS INNOVACIÓN PARA LA EXCELENCIA	GUIA DE USO DE LABORATORIO	 FECHA: 2024-01-26
---	-----------------------------------	--

A. INFORMACIÓN DE LA GUÍA

DEPARTAMENTO:	DEPARTAMENTO DE CIENCIAS DE LA COMPUTACION	CARRERA:	CARRERA DE SOFTWARE		
ASIGNATURA:	APL. BASADAS EN EL CONOCIMIENTO	PERIODO:	NOV2023-MAR2024	NIVEL:	SEXTO NIVEL
DOCENTE:	ING. JOSE LUIS CARRILLO MEDINA	NRC:	14201	PRÁCTICA No:	6
LABORATORIO DONDE SE DESARROLLARÁ LA PRÁCTICA:		LE SALA: INGENIERIA DE SOFTWARE			
TEMA DE LA PRÁCTICA:	Implementación de Modelos de Reducción de la Dimensionalidad en Machine Learning			NUMERO DE HORAS:	2

INTRODUCCIÓN:

La reducción de la dimensionalidad es esencial para trabajar eficientemente con conjuntos de datos de alta dimensión, permitiendo una representación más compacta y facilitando el análisis. Algunas técnicas como el Análisis de Componentes Principales (PCA) y t-Distributed Stochastic Neighbor Embedding (t-SNE), se implementan utilizando bibliotecas como scikit-learn. El PCA es una técnica de reducción de la dimensionalidad que se utiliza para transformar un conjunto de datos de alta dimensionalidad en un conjunto de dimensiones más bajas, llamadas componentes principales. Funciona encontrando la dirección de máxima variabilidad en los datos y proyectando los datos originales sobre esta dirección. Los componentes principales son ortogonales entre sí y ordenados por la cantidad de varianza que capturan. Al seleccionar solo los primeros componentes principales, se logra una representación más compacta del conjunto de datos original. t-SNE es una técnica de reducción de la dimensionalidad que se utiliza principalmente para visualizar datos de alta dimensión en un espacio bidimensional o tridimensional. A diferencia de PCA, t-SNE se centra en preservar las relaciones entre las distancias locales entre puntos en el conjunto de datos original. Funciona construyendo una distribución de probabilidad conjunta sobre pares de puntos en el espacio original y una distribución similar en el espacio de baja dimensión. Luego, minimiza la divergencia de Kullback-Leibler entre estas dos distribuciones para encontrar una representación visualmente significativa.

OBJETIVOS:

Introducir a los participantes en la implementación de modelos de reducción de la dimensionalidad en el contexto del aprendizaje automático. Se explorarán técnicas que permiten representar datos de alta dimensionalidad de manera más compacta y eficiente.

EQUIPOS:

Computador Proyector Pizarra

MATERIALES E INSUMOS:

Lenguaje de programación Python instalado Librería sklearn instalado

REACTIVOS:

NA

MUESTRA / OTROS:

NA

PRECAUCIONES/ INSTRUCCIONES:

1. Revisar conceptos clave 2. Analizar e implementar PCA 3. Mostrar resultados con PCA. 4. Aplicación en Conjuntos de Datos 5. Implementar modelos de machine learning (por ejemplo, clasificación) en el conjunto de datos original y reducido. 5. Evaluar el impacto en términos de rendimiento y eficiencia computacional. 6. Discusión y Conclusiones

ACTIVIDADES POR DESARROLLAR:

1. Introducción a la Reducción de la Dimensionalidad 1.1. Revisar conceptos clave: ¿Por qué reducir la dimensionalidad? ¿Cuáles son los beneficios y desafíos 2. Técnicas de Reducción de la Dimensionalidad 2.1 Análisis de Componentes Principales (PCA) 2.2 Implementar PCA Utilizar bibliotecas como scikit-learn para aplicar PCA. 3. Aplicación en Conjuntos de Datos 3.1. Seleccionar un conjunto de datos de alta dimensión. 3.2. Aplicar las técnicas de reducción de la dimensionalidad y comparar los resultados. 4. Evaluación del Impacto en Modelos de Machine Learning 4.1. Implementar modelos de machine learning (por ejemplo, clasificación) en el conjunto de datos original y reducido. 4.2. Evaluar el impacto en términos de rendimiento y eficiencia computacional. 5. Discusión y Conclusiones 5.1 Reflexionar sobre los resultados obtenidos. 5.2 Discutir las aplicaciones prácticas y limitaciones de la reducción de la dimensionalidad.

RESULTADOS OBTENIDOS:

El alumno estará en capacidad de: Comprender los motivos y beneficios de la reducción de la dimensionalidad. Implementar PCA para reducción de la dimensionalidad. Aplicar técnicas en conjuntos de datos reales. Evaluar el impacto de la reducción de la dimensionalidad en modelos de Machine Learning. Discutir las consideraciones prácticas y aplicaciones de estas técnicas.

CONCLUSIONES:

Este laboratorio proporcionará a los alumnos una experiencia práctica en la implementación y evaluación de modelos de reducción de la dimensionalidad en el contexto del aprendizaje automático.

RECOMENDACIONES:

Trabajar con datos más complejos para una mejor comprensión de cómo las técnicas de reducción de la dimensionalidad, como PCA, simplifican la representación de datos y mejoran la eficiencia de los modelos de aprendizaje automático

B. CONTROL DE CAMBIOS

Fecha	Versión	Unidad / Nombre	Detalle del cambio
-------	---------	-----------------	--------------------

 ESPE UNIVERSIDAD DE LAS FUERZAS ARMADAS INNOVACIÓN PARA LA EXCELENCIA	GUIA DE USO DE LABORATORIO		 FECHA: 2024-01-26
05 - mayo - 2023	1	Sección de Planificación / Ing. Eddie Galarza	Versión Inicial

C. APROBACIÓN

Rubro	Nombres y Apellido	Unidad / Cargo	Firma
Elaborado por:	ING. JOSE LUIS CARRILLO MEDINA	Docente	
Revisado por:	ING. CARRILLO MEDINA JOSE LUIS	Coordinador de Área de Conocimiento	
Aprobado por:	ING. SANTIAGO JáCOME. PHD.	Coordinador / Jefe de Laboratorio	

